Détection de zones par montée de gradient d'un rectangle dans le flou gaussien

Noé Aubin-Cadot

22 mars 2020

But

<u>But</u>: Détecter des régions statistiquement peu probables dans un nuage de points à valeurs binaires.

<u>Idée</u>: À l'aide d'un noyau gaussien, construire une fonction plutôt lisse sur laquelle un rectangle glisse en suivant une montée de gradient vers une région où il se passe quelque chose.


Plan

Plan:

- 1. Visualiser le problème.
- 2. Algorithme de détections.
- 3. Utilisation de l'algorithme.
- 4. Réflexions à propos de l'algorithme.


Visualiser le problème

On considère un nuage de m points dans un espace de dimension n. Chaque point est à valeurs binaires $\{0, 1\}$.




Visualiser le problème


On cherche des régions où la proportion locale de 0 et de 1 est éloignée de la proportion globale de 0 et de 1.




D'abord, on découpe le nuage de points selon une grille de résolution $k_1 \times k_2 \times ... \times k_n$.




On voit chaque case comme un pixel dont la couleur est la proportion locale de 0 et de 1 moins la proportion globale.




On fait alors une convolution avec un noyau gaussien:




La nouvelle image obtenue est plus lisse :




En modifiant l'écart-type σ du noyau gaussien on peu effacer ou garder plus ou moins de détails locaux :




Considérons cet autre nuage de points :



On classifie les points dans des pixels :



On y applique le noyau gaussien :




Maintenant qu'on a une image lisse, un rectangle peut suivre le gradient pour trouver des régions où la proportion locale est éloignée de la proportion globale.


On commence avec un rectangle en position aléatoire :




On laisse aller le rectangle dans le gradient du flou gaussien :



On constate où le rectangle a convergé :



Le flou gaussien permet de détecter des régions éloignées :



Réflexions à propos de l'algorithme

En dimension n = 2 l'algorithme est très rapide, même pour un très grand nombre m de points.

Il est aussi possible de l'étendre aux données incomplètes. Un "point" dont on ne sait certaines coordonnées est un sous-espace. Un sous-espace est envoyé, via le noyau gaussien, à une gaussienne qui est constante dans les directions inconnues.

Réflexions à propos de l'algorithme

Toutefois, en dimension $n \gg 2$, l'application numérique du noyau gaussien devient très lourd en calculs et en mémoire.

Par exemple, en dimension n = 600, pour une résolution de 10 dans chaque dimension, on doit s'occuper de 10^{600} cases, ce qui est bien plus grand que $\approx 10^{80}$, le nombre d'atomes dans l'univers.

Merci de votre attention ©

